

Metodologia de Preparação, Síntese e Validação de Dados (QIP) – Versão Revisada

Resia Silva de Moraes

20 de setembro de 2025

1 Visão geral

A metodologia adotada baseia-se em: (i) preparar a base real; (ii) calibrar uma heurística de decisão multi-classe; (iii) sintetizar dados condicionais por classe com um cWGAN-GP; (iv) treinar, **exclusivamente com os dados sintéticos gerados na etapa anterior**, um modelo heurístico baseado em *softmax*; e (v) validar o desempenho em um conjunto externo não utilizado em nenhuma etapa anterior. A abordagem foi concebida para cenários de amostras escassas e classes desbalanceadas, garantindo rastreabilidade e separação rigorosa entre *dados para análise* e *dados para validação*.

2 Preparação dos dados e “Seleção de Dados”

2.1 Base original e limpeza

A base original, extraída do questionário QIP, contém variáveis numéricas e um alvo categórico. Amostras com rótulo *desconhecido* (e.g., *não/nao*) são removidas antes de qualquer etapa posterior. Esse procedimento evita viés no condicionamento do gerador e impede contaminação do conjunto de validação.¹

2.2 Seleção de atributos orientada

Adota-se o critério de **não utilizar variáveis demográficas** e/ou outras perguntas cuja influência seja difícil de analisar por conhecimentos heurísticos. Essa filtragem reduz dimensionalidade e preserva apenas atributos com contribuição informativa prévia. Regras adicionais de exclusão podem ser incorporadas (por exemplo, uma *regra de ouro* baseada em pontuações).

2.3 Tratamento de classes raras

Classes com menos de um limiar mínimo de amostras são removidas (p.ex., ≤ 2 respostas). Essa decisão evita falhas em procedimentos que requerem pelo menos duas amostras por classe (e.g., vizinhanças do SMOTE) e estabiliza a estimação de parâmetros condicionais.²

¹Implementação de remoção e normalização do alvo nos scripts de pré-processamento.

²Contagens por classe, limiar adotado e remoções são registradas em log e planilhas de saída.

3 Heurística de decisão (calibração de W)

3.1 Mudança de faixa e motivação

Inicialmente, a heurística considerou pesos $W \in [0, 1]$. Após testes, adotou-se $W \in [-1, 1]$, o que promoveu melhor discriminação: ao reforçar a classe correta, penaliza-se as demais. Observou-se incremento de desempenho em validações internas (e.g., $\approx 36\% \rightarrow 45\%$).

3.2 Formulação

Seja $X \in \mathbb{R}^{n \times d}$ o conjunto de atributos e $W \in \mathbb{R}^{(d+1) \times K}$ os pesos (incluindo viés). As probabilidades são $P = \text{softmax}(X_b W)$, com X_b denotando X acrescido de 1s (viés). A calibração maximiza uma métrica alvo (macro top- k) sob restrições: máscara de atributos permitidos (consistente com a seleção anterior), projeção em $[-1, 1]$ nos pesos dos atributos e *early stopping* por platô.

4 Síntese condicional com cWGAN-GP

4.1 Separação analítica vs. validação externa

A base é dividida em duas metades aproximadamente estratificadas: **(A)** metade para *análise* (treino/ajuste) e **(B)** metade para *validação externa*, que não participa de nenhuma etapa de ajuste (nem cWGAN, nem heurística).

4.2 Balanceamento e condicionamento

Na metade A, a distribuição por classe é balanceada com *oversampling* (SMOTE com *fall-back* para amostragem aleatória com reposição, quando necessário). Em seguida, treina-se um cWGAN-GP condicional por classe, operando em espaço escalado $[0, 1]$ e revertendo ao espaço original para análise. Variáveis binárias e inteiras (0..10) são arredondadas na exportação dos dados sintéticos.

4.3 Geração de dados sintéticos

O cWGAN é aplicado exclusivamente na metade A para gerar amostras virtuais, ampliando a cobertura de padrões sob as distribuições condicionais de classe. A metade B permanece preservada para validação externa.

5 Treinamento final (softmax/heurística) com dados sintéticos de A

O modelo heurístico final é treinado **somente sobre os dados sintéticos** produzidos a partir da metade A, mantendo as mesmas restrições de projeto (máscara de atributos, projeção $[-1, 1]$, *early stopping*). Essa etapa consolida um classificador *softmax* que generaliza a partir de exemplos gerados.

6 Validação externa e análises estatísticas

A heurística final é aplicada **exclusivamente** na metade B (jamais vista). Em seguida, são conduzidas as análises estatísticas e de qualidade: macro top- k (para $k = 1, 2, 3$), métricas por classe (acerto/suporte), bem como KS , diferença de proporções de classe e *gap* de correlação quando pertinente.

7 Fluxograma do processo (versão revisada)

8 Parâmetros e escolhas de projeto

- **Seleção de dados:** exclusão explícita de variáveis demográficas/itens de difícil interpretação; limiar mínimo de suporte por classe;
- **Heurística:** pesos de atributos projetados em $[-1, 1]$; viés livre; *early stopping*;
- **cWGAN-GP:** dimensão de ruído z , largura/profundidade das camadas, n_{critic} , penalidade de gradiente, ruído de instância opcional;
- **Balanceamento:** alvo total de amostras e estratégia (SMOTE com *fallback* ROS/duas passadas);
- **Avaliação:** frequência de avaliação e relatórios automáticos.




Figura 1: Fluxograma revisado: o treinamento final usa **apenas sintéticos (A)** e a validação ocorre na **Metade B**; as análises estatísticas são realizadas **após** a validação.