

Referencial Teórico e Metodologia (Fluxo Corrigido)

Trabalho de Conclusão de Curso

20 de setembro de 2025

Capítulo 1

Referencial Teórico

1.1 Preparação dos dados e seleção de atributos

Considera-se um conjunto de dados tabulares $X \in \mathbb{R}^{n \times d}$ e um alvo categórico $y \in \{1, \dots, K\}^n$. Em aplicações clínicas baseadas em questionários, como no contexto de saúde mental, itens psicométricos validados — por exemplo, o *Major Depression Inventory* (MDI) — funcionam como *sinais* (“sensores” *proxy*) do estado latente do respondente, devendo ser priorizados em detrimento de variáveis demográficas quando o objetivo é reduzir vieses e aumentar interpretabilidade [1, 2].

Limpeza e padronização. Amostras com rótulos desconhecidos ou inconsistentes devem ser removidas antes da modelagem, por prevenirem viés no condicionamento de geradores e em classificadores supervisionados [3]. Valores ausentes em X podem ser imputados por estratégias robustas (mediana) e variáveis numéricas devem ser normalizadas quando exigido por algoritmos subsequentes.

Seleção informada de atributos. Seja $\mathcal{S} \subseteq \{1, \dots, d\}$ o subconjunto de atributos de interesse, definido por critérios substantivos (itens clínicos *interpretáveis*) ou por uma máscara de relevância prévia. A matriz de trabalho é $X_{\mathcal{S}} = X[:, \mathcal{S}]$. A priori externa (derivada de literatura/escala) pode ser registrada como matriz $W_0 \in \mathbb{R}^{(|\mathcal{S}|+1) \times K}$ para apoiar regularizações posteriores (Seção de Metodologia).

Tratamento de classes raras. Dadas contagens $n_k = |\{i : y_i = k\}|$, estabelece-se um limiar $n_k \geq n_{\min}$ (p.ex., $n_{\min} = 2$) para manter estabilidade numérica em vizinhanças (e.g., SMOTE) e confiabilidade em métricas por classe [3].

1.2 Divisão estratificada 50/50: *análise* vs. *validação*

Amostras são bipartidas de forma estratificada em dois subconjuntos disjuntos: $\mathcal{A}$ (“metade A”, para *análise*) e $\mathcal{B}$ (“metade B”, para *validação externa*). A independência entre $\mathcal{A}$ e $\mathcal{B}$ evita vazamento de informação e permite estimativa imparcial de generalização [12].

1.3 Balanceamento prévio (SMOTE/ROS) na metade A

Desbalanceamento entre classes pode deteriorar tanto geradores condicionais quanto classificadores [3]. Um método amplamente aceito é o *Synthetic Minority Over-sampling Technique* (SMOTE) [4]: para uma amostra minoritária $\mathbf{x}_i$ e um vizinho $\mathbf{x}_{nn}$, gera-se

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1). \quad (1.1)$$

Caso não haja vizinhança suficiente, utiliza-se *oversampling* aleatório com reposição (ROS) como mecanismo de robustez [3].

1.4 Síntese condicional com cWGAN-GP

Considere um gerador $G(\mathbf{z}, \mathbf{c})$ e um crítico $D(\mathbf{x}, \mathbf{c})$ condicionados pelo rótulo $\mathbf{c} \in \{0, 1\}^K$ (*one-hot*). O *Wasserstein GAN* [5] com penalidade de gradiente [6] otimiza

$$\begin{aligned} \mathcal{L}_D = & -\mathbb{E}_{(\mathbf{x}, \mathbf{c}) \sim p_{\text{real}}} [D(\mathbf{x}, \mathbf{c})] + \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(0, I), \mathbf{c}} [D(G(\mathbf{z}, \mathbf{c}), \mathbf{c})] \\ & + \lambda \mathbb{E}_{\hat{\mathbf{x}}} \left(\left\| \nabla_{\hat{\mathbf{x}}} D(\hat{\mathbf{x}}, \mathbf{c}) \right\|_2 - 1 \right)^2, \end{aligned} \quad (1.2)$$

$$\mathcal{L}_G = -\mathbb{E}_{\mathbf{z} \sim \mathcal{N}(0, I), \mathbf{c}} [D(G(\mathbf{z}, \mathbf{c}), \mathbf{c})], \quad (1.3)$$

com amostras interpoladas para a penalidade

$$\hat{\mathbf{x}} = \alpha \mathbf{x}_{\text{real}} + (1 - \alpha) \mathbf{x}_{\text{fake}}, \quad \alpha \sim \mathcal{U}(0, 1). \quad (1.4)$$

A condição de Lipschitz é imposta pela penalidade quadrática no desvio da norma do gradiente para 1 [6]. Em variáveis tabulares, é prática comum aplicar normalização por atributo no intervalo $[0, 1]$ durante o treinamento e reverter ao domínio original na geração, assegurando *post-processing* para variáveis discretas (binárias e inteiras).

Utilidade do sintético. Para avaliar se amostras sintéticas são *úteis* e não apenas *verossímeis*, emprega-se a métrica TSTR (*Train on Synthetic, Test on Real*), popularizada em dados médicos temporais [7, 8].

1.5 Treinamento final de uma heurística *softmax* com dados sintéticos

Seja $X_b \in \mathbb{R}^{n \times (d+1)}$ a matriz de atributos com viés (coluna de 1s) e $W \in \mathbb{R}^{(d+1) \times K}$ a matriz de parâmetros. O modelo *softmax* produz, para a amostra i ,

$$p_{ik} = \frac{\exp((X_b W)_{ik})}{\sum_{\ell=1}^K \exp((X_b W)_{i\ell})}, \quad P = \text{softmax}(X_b W). \quad (1.5)$$

Admitindo rótulos *one-hot* $\mathbf{y}_i$ (ou distribuições alvo $Y \in [0, 1]^{n \times K}$), a função de perda média é a entropia cruzada

$$\mathcal{L}_{\text{CE}}(W) = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K Y_{ik} \log p_{ik}, \quad (1.6)$$

cujo gradiente é o clássico [10]:

$$\nabla_W \mathcal{L}_{\text{CE}}(W) = X_b^\top \frac{(P - Y)}{n}. \quad (1.7)$$

Para incorporar uma a priori W_0 e induzir parcimônia/estabilidade, emprega-se regularização elástica *ao redor* de W_0 ,

$$\mathcal{R}(W; W_0) = \lambda_1 \|W - W_0\|_1 + \lambda_2 \|W - W_0\|_F^2, \quad (1.8)$$

levando ao problema

$$\min_W \mathcal{L}_{\text{CE}}(W) + \mathcal{R}(W; W_0) \quad \text{sujeito a} \quad W_{\text{feat}} \in [-1, 1], \quad (1.9)$$

em que apenas pesos associados a atributos selecionados podem variar, enquanto limites em $[-1, 1]$ promovem interpretabilidade. A atualização de W pode ser feita por *gradiente proximal* [11]:

$$\widetilde{W} \leftarrow W - \eta \left(\nabla_W \mathcal{L}_{\text{CE}}(W) + 2\lambda_2(W - W_0) \right), \quad (1.10)$$

$$W \leftarrow \text{proj}_{[-1, 1]} \left(W_0 + \text{soft}(\widetilde{W} - W_0, \eta\lambda_1) \right), \quad (1.11)$$

onde $\text{soft}(u, \tau) = \text{sign}(u) \max\{|u| - \tau, 0\}$ é o *soft-thresholding* e $\text{proj}_{[-1, 1]}$ projeta componentes dos atributos para o intervalo permitido. Critérios de *early stopping* [12] controlam o platô em validação.

1.6 Validação externa e métricas estatísticas

A validação externa utiliza unicamente as amostras em $\mathcal{B}$. Para além de acurácia e *macro top-k* (média entre classes da fração de ocorrências em que o rótulo verdadeiro está entre as k maiores probabilidades), são empregadas métricas de proximidade distribuição-síntese:

- **KS univariado** por atributo: a estatística de Kolmogorov–Smirnov compara $F_{\text{real}}(x)$ e $F_{\text{sint}}(x)$ [13];
- **Hiato de correlação**: mede-se $\|\text{Corr}(X_{\text{real}}) - \text{Corr}(X_{\text{sint}})\|_F$; a norma de Frobenius é um operador natural para distâncias matriciais [14];
- **Desvio de proporções de classe**: diferenças absoluta média e máxima entre proporções de rótulos reais e sintéticos.

Para utilidade do sintético em classificação, a métrica TSTR é particularmente informativa [7, 8, 9]: treina-se um classificador simples em dados sintéticos e mede-se seu desempenho em dados reais.

Conclusão

O encadeamento proposto — limpeza e seleção interpretável de atributos, divisão estratificada com independência de validação, balanceamento robusto, síntese condicional com WGAN-GP, treinamento *softmax* regularizado ao redor de uma a priori e validação externa com métricas de verossimilhança e utilidade — constitui uma base teórica sólida para análise em cenários de amostras escassas e classes desbalanceadas.

Referências Bibliográficas

- [1] P. Bech, A. Rafaelsen, et al. The Major Depression Inventory (MDI): validity and reliability. *Journal of Affective Disorders*, 66(2–3):159–164, 2001.
- [2] L. R. Olsen, P. Jensen, P. Bech. The sensitivity and specificity of the Major Depression Inventory, using the present state examination as the index of diagnostic validity. *Journal of Affective Disorders*, 73(1–2): 133–138, 2003.
- [3] H. He and E. A. Garcia. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9):1263–1284, 2009.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [5] M. Arjovsky, S. Chintala, L. Bottou. Wasserstein Generative Adversarial Networks. In *Proc. ICML*, 2017.
- [6] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, A. Courville. Improved Training of Wasserstein GANs. In *Proc. NeurIPS*, 2017.
- [7] J. Yoon, D. Jarrett, M. van der Schaar. Time-series Generative Adversarial Networks. *NeurIPS*, 2019. (Usa TSTR como métrica de utilidade).
- [8] C. Esteban, S. Hyland, G. Rätsch. Real-valued (Medical) Time Series Generation with Recurrent GANs. *arXiv:1706.02633*, 2017. (Populariza TSTR).
- [9] L. Xu, M. Skoularis, A. Veeramachaneni. Modeling Tabular Data using Conditional GAN. *NeurIPS Workshop on Causal Learning*, 2019.
- [10] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [11] N. Parikh and S. Boyd. Proximal Algorithms. *Foundations and Trends in Optimization*, 1(3):127–239, 2014.
- [12] L. Prechelt. Early Stopping — But When? In *Neural Networks: Tricks of the Trade*, Springer, 1998.
- [13] F. J. Massey. The Kolmogorov–Smirnov test for goodness of fit. *Journal of the American Statistical Association*, 46(253):68–78, 1951.

- [14] G. H. Golub, C. F. Van Loan. *Matrix Computations* (4th ed.). Johns Hopkins University Press, 2013.
- [15] R. Shokri, M. Stronati, C. Song, V. Shmatikov. Membership Inference Attacks Against Machine Learning Models. In *Proc. IEEE S&P*, 2017.

Capítulo 2

Metodologia (Fluxo Corrigido)

Este capítulo descreve, em ordem estrita, o fluxo metodológico adotado. O encadeamento parte da preparação dos dados reais, prossegue pela divisão estratificada em conjuntos de análise e validação, realiza o balanceamento e a síntese condicional com *cWGAN-GP*, avalia a qualidade estatística das amostras sintéticas, e somente então treina a heurística *softmax* com tais amostras. Ao final, procede-se à validação externa exclusiva no conjunto de validação.

2.1 Preparação e seleção de atributos

Parte-se de dados tabulares oriundos de um questionário clínico. São removidas observações cujo rótulo de classe seja desconhecido ou inconsistente. A seleção de atributos privilegia itens clínicos interpretáveis e exclui variáveis demográficas e questões cujo efeito seja de difícil justificativa heurística. Valores ausentes são tratados por imputação robusta e as variáveis são padronizadas quando requerido pelos métodos subsequentes.

2.2 Divisão estratificada 50/50

O conjunto é bipartido em duas metades aproximadamente estratificadas: **Metade A** (análise) e **Metade B** (validação externa). A Metade B permanece totalmente intocada até a etapa de validação final, preservando a independência estatística entre ajuste e avaliação [12].

2.3 Balanceamento prévio na Metade A

Devido ao desbalanceamento entre classes, aplica-se *oversampling* na Metade A para estabilizar o treinamento dos modelos condicionais. Prioriza-se o *SMOTE* [4]; quando não houver vizinhanças suficientes, recorre-se ao *oversampling* aleatório com reposição (ROS) [3].

2.4 Síntese condicional com cWGAN–GP

Na Metade A, treina-se um gerador adversarial condicional (*cWGAN–GP*) [5, 6] para modelar a distribuição de atributos condicionada à classe. O treinamento observa normalização por atributo durante o ajuste e reversão ao domínio original na geração, incluindo pós-processamento para atributos discretos. Como medida de utilidade das amostras geradas, considera-se a métrica TSTR (*Train on Synthetic, Test on Real*) [7, 8].

2.5 Avaliação estatística da síntese

Concluído o treinamento do cWGAN–GP, procede-se à avaliação estatística das amostras sintéticas, contemplando: (i) estatística de Kolmogorov–Smirnov (KS) por atributo [13]; (ii) hiato de correlação via norma de Frobenius entre correlações real e sintética [14]; (iii) diferenças de proporções por classe; e (iv) utilidade medida por TSTR. Essa etapa antecede qualquer treinamento de heurística, garantindo que apenas amostras sintéticas com qualidade adequada sirvam de insumo.

2.6 Treinamento final da heurística *softmax* com dados sintéticos

Somente após a avaliação estatística, treina-se o classificador *softmax* com viés. Seja X_b a matriz de atributos com coluna de 1s e W a matriz de parâmetros; as probabilidades preditas são $P = \text{softmax}(X_b W)$. A estimação minimiza a entropia cruzada média com regularização elástica ao redor de uma a priori W_0 , empregando gradiente proximal com projeção dos pesos de atributos a um intervalo limitado para promover interpretabilidade [10, 11].

2.7 Uso estrito da Metade B (50 observações) para validação externa

Os 50 registros da Metade B são utilizados *exclusivamente* para validação final do modelo treinado com dados sintéticos. Nenhum procedimento de ajuste — seja do cWGAN–GP, seja da heurística — emprega exemplos da Metade B. Após a inferência no conjunto de validação, reportam-se as métricas de desempenho (macro top- k e por classe) e repete-se, quando pertinente, a bateria de comparações distribuição-síntese para auditoria final. Esse arranjo assegura estimativas imparciais de generalização.

Fluxograma do processo (atualizado)




Figura 2.1: Fluxo atualizado: avaliação estatística ANTES do treinamento final da heurística; validação exclusiva na Metade B.