

Softmax, Ajuste de Pesos, Classe *Sem Transtorno* e Método Ensemble

Guia didático e objetivo

1 de setembro de 2025

1 Softmax: do escore à probabilidade relativa

Considere um vetor de escores (também chamados de *logits*) $s = (s_1, \dots, s_K) \in \mathbb{R}^K$. A função **softmax** produz uma distribuição de probabilidades $p = (p_1, \dots, p_K)$ tal que $p_k \in (0, 1)$ e $\sum_k p_k = 1$:

$$\text{softmax}(s)_k = \frac{e^{s_k}}{\sum_{t=1}^K e^{s_t}}. \quad (1)$$

Para estabilidade numérica, subtrai-se $\max(s)$ (não altera o valor final):

$$\text{softmax}(s)_k = \frac{e^{s_k - \max(s)}}{\sum_{t=1}^K e^{s_t - \max(s)}}. \quad (2)$$

Intuição. As exponenciais ampliam diferenças: uma pequena vantagem em s_k pode virar uma vantagem maior em p_k . A normalização pela soma garante que os p_k somem 1, permitindo comparar classes em uma mesma linha.

Temperatura (opcional). Controla a “nitidez” das probabilidades:

$$\text{softmax}_T(s)_k = \frac{e^{s_k/T}}{\sum_t e^{s_t/T}}, \quad (3)$$

com $T < 1$ deixando a distribuição mais “dura” (top-1 maior) e $T > 1$ mais “suave”.

2 Ajuste de pesos: como melhorar sem “estragar” o questionário

Seja $X \in [0, 1]^{n \times m}$ a matriz de respostas (linhas = casos, colunas = itens/perguntas) e $W \in [0, 1]^{m \times K}$ a matriz de pesos (colunas = classes). Calculamos notas lineares S e probabilidades P por:

$$S = XW \quad \text{e} \quad P_{i,:} = \text{softmax}(S_{i,:}). \quad (4)$$

Objetivo e métrica

Nosso objetivo é aumentar a taxa de acerto por classe no **top-3** (“macro top-3”), isto é, a média (entre classes) da fração de linhas em que a classe verdadeira aparece entre as 3 maiores probabilidades. Para suportar alvos com *múltiplos rótulos*, definimos uma distribuição-alvo por linha $Y \in [0, 1]^{n \times K}$ onde, para os rótulos presentes na linha i , atribuímos pesos iguais que somam 1.

Restrições práticas que mantêm a estrutura do questionário

- **Apenas colunas ajustáveis:** uma coluna (feature) j só é ajustada se houver ao menos um valor $X_{:,j} > 0$. Colunas com $X_{:,j} = 0$ para todas as linhas são *congeladas* e mantidas exatamente como no W_0 original (não são zeradas nem alteradas).
- **Limites dos pesos:** para colunas ajustáveis, projetamos W no intervalo $[\varepsilon, 1]$ (com ε pequeno).
- **Proximidade ao original:** penalizamos desvios em relação a W_0 (pesos originais) via *Elastic Net* (combinação de L1 e L2).

Função de perda e otimização

Minimizamos a entropia cruzada média entre P e Y (somente nas classes clínicas tradicionais) com penalização elástica em torno de W_0 :

$$\mathcal{L}(W) = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K Y_{ik} \log P_{ik} + \lambda_1 \|W - W_0\|_1 + \lambda_2 \|W - W_0\|_2^2. \quad (5)$$

Após cada passo de gradiente/proximal, aplicamos a projeção

$$\Pi(W) = \begin{cases} W_{j,:} \leftarrow W_{0j,:}, & \text{se } \max_i X_{ij} = 0 \quad (\text{coluna congelada}) \\ W_{j,:} \leftarrow \text{clip}(W_{j,:}, \varepsilon, 1), & \text{caso contrário (ajustável)}. \end{cases} \quad (6)$$

Paramos quando não há melhora do macro top-3 (ou ao atingir uma meta).

3 Classe *Sem Transtorno* por regra de “baixa ativação”

As features medem *presença* de sintomas; por isso, ao invés de criar uma 12ª coluna em W para o “normal”, introduzimos a classe **Sem Transtorno** por uma **regra** aplicada sobre as probabilidades já calculadas P (com $K = 11$ classes).

Quando a regra aciona?

Para cada linha, definimos:

$$p^{(1)} = \max_k P_k \quad (\text{probabilidade top-1}), \quad (7)$$

$$p^{(2)} = \text{segunda maior probabilidade}, \quad (8)$$

$$\Delta = p^{(1)} - p^{(2)} \quad (\text{margem}). \quad (9)$$

A regra aciona se

$$p^{(1)} < T_1 \quad \text{e} \quad \Delta < T_2, \quad (10)$$

senalizando que não há classe fortemente ativada e há pouca separação em relação à segunda colocada.

Como atribuímos probabilidade ao *Sem Transtorno*?

Se a regra aciona, alocamos uma fração γ à nova classe e reescalamos as demais probabilidades para manter soma 1. Dado $P \in \mathbb{R}^K$,

$$P' = \begin{cases} [(1 - \gamma)P; \gamma], & \text{se aciona} \\ [P; 0], & \text{se não aciona} \end{cases} \quad (11)$$

onde $P' \in \mathbb{R}^{K+1}$ inclui a posição extra para *Sem Transtorno*. O ranking (top-1/top-2/top-3) passa a considerar $K+1$ classes.

Como escolhemos T_1 , T_2 e γ ? (busca em grade)

Avaliamos diversas combinações (T_1, T_2, γ) e escolhemos a que maximiza o **macro top-3 incluindo** a classe *Sem Transtorno*. Para isso, mapeamos respostas “não” no *Alvo* para este novo rótulo e computamos a taxa de acerto por classe (aparece no top-3) e depois a média entre classes com suporte > 0 .

Exemplo numérico. Suponha $P = [0,24, 0,22, 0,18, \dots]$, então $p^{(1)} = 0,24$, $p^{(2)} = 0,22$, $\Delta = 0,02$. Se a melhor tripla for $T_1=0,30$, $T_2=0,06$, $\gamma=0,50$, a regra aciona e obtemos

$$P' = [0,12, 0,11, 0,09, \dots, 0,50], \quad (12)$$

onde 0,50 é $p_{\text{Sem Transtorno}}$ e as demais probabilidades foram multiplicadas por $(1-\gamma) = 0,5$.

4 Método Ensemble Heurístico–Discriminativo

Combinamos duas fontes de probabilidade e, depois, aplicamos a regra de “Sem Transtorno”:

1. Heurística linear (interpretável):

$$s^{(H)} = XW, \quad p^{(H)} = \text{softmax}(s^{(H)}) \in \mathbb{R}^K. \quad (13)$$

2. Modelo supervisionado (discriminativo):

treinamos um classificador multiclasse (ex.: Logística multinomial). Denotamos

$$p^{(M)} = \text{probas_do_modelo}(X) \in \mathbb{R}^K \quad \text{com} \quad \sum_{k=1}^K p_k^{(M)} = 1. \quad (14)$$

3. Mistura convexa (ensemble):

$$p = (1 - \alpha) p^{(H)} + \alpha p^{(M)}, \quad \alpha \in [0, 1]. \quad (15)$$

Escolhemos α por validação (OOV/CV) maximizando *macro top-3*.

4. Pós-regra para *Sem Transtorno*:

sobre p , calculamos $p^{(1)}$ e a margem Δ ; se $p^{(1)} < T_1$ e $\Delta < T_2$, alocamos γ para a classe *Sem Transtorno* e reescalamos as demais (como na Seção anterior).

Boas práticas.

- **Calibração** do modelo supervisionado antes da mistura (Platt, isotônica ou temperatura).
- **Sintonizar** α na mesma métrica (macro top-3) usada pelo projeto.
- **Aplicar a regra** de *Sem Transtorno* após a mistura, pois ela mede a incerteza global.
- **Versionar** W , α , (T_1, T_2, γ) e as métricas, para rastreabilidade.

5 Leitura das planilhas geradas

- **Pontuação_Tunada:** matriz de pesos W após o ajuste (colunas congeladas iguais ao W_0 , ajustáveis em $[\varepsilon, 1]$).
- **Resultado_Heuristica_Tunada:** probabilidades $p_{\langle \text{classe} \rangle}$, a coluna $p_{\text{Sem Transtorno}}$ e o ranking top-1/top-2/top-3 com as $K+1$ classes.
- **Metricas_Heuristica_Tunada:** macro top-3 (incluindo *Sem Transtorno*) e tabela por classe (taxa de top-3, suporte).
- **Regras_Normal:** valores aprendidos (T_1, T_2, γ) , taxa de acionamento e métrica final.

Observação. Por configuração, podemos também exigir que uma coluna só seja ajustável se, além de $X_{:,j}$ ter algum valor > 0 , a coluna correspondente em W_0 possuir ao menos um peso diferente de zero (mantendo a *sparsidade* original).